データの分析

代表値と箱ひげ図

平均値 $\bar{x} = \dfrac{1}{n}(x_1 + x_2 + \cdots + x_n)$
中央値：大きさの順に並べた真ん中（偶数個なら真ん中2つの平均）

四分位数 Q_1, Q_2, Q_3：中央値で前半・後半に分け（奇数個なら中央値を除く）、それぞれの中央値が Q_1, Q_3
四分位範囲 $Q_3 - Q_1$
箱ひげ図：最小値・Q_1・Q_2・Q_3・最大値
外れ値：$Q_1 - 1.5(Q_3 - Q_1)$ 以下、または $Q_3 + 1.5(Q_3 - Q_1)$ 以上

分散・標準偏差

$s^2 = \dfrac{1}{n}\sum(x_i - \bar{x})^2 = \overline{x^2} - (\bar{x})^2$
（2乗の平均 − 平均の2乗）
標準偏差 $s = \sqrt{s^2}$

2つの変量

共分散 $s_{xy} = \dfrac{1}{n}\sum(x_i - \bar{x})(y_i - \bar{y})$

相関係数 $r = \dfrac{s_{xy}}{s_x s_y}$，　$-1 \leqq r \leqq 1$

散布図が右上がりに直線に近いほど r は 1 に近い。

変量の変換

$y = ax + b$ のとき

$\bar{y} = a\bar{x} + b$，　$s_y^2 = a^2 s_x^2$，　$s_y = |a| s_x$

$u = ax + b$, $v = cy + d$ のとき

$s_{uv} = ac\, s_{xy}$

相関係数は $ac > 0$ なら変わらない、$ac < 0$ なら符号だけ逆

仮説検定の考え方

1. 主張したいことと**反対の仮説**を立てる
2. その仮説のもとで、実際の結果（以上に極端なこと）が起こる確率を調べる
3. 確率が基準（例：5%）より小さい → 仮説は正しくないと考え、主張は正しいと判断する
4. 小さくない → **判断できない**（主張がまちがいとは言えない）

共テでは

いくつもの箱ひげ図・ヒストグラム・散布図から「正しいものをすべて選べ」。1つずつ図で確かめる。

よくあるミス

- 箱ひげ図から平均値を読もうとする（読めない）
- 「判断できない」を「仮説が正しい」とする
- 分散の単位は元の単位の2乗